

OAT 1 – Mecânica João Pessoa

Autores: Arthur de Aquino Anjo
Henrique Estrela Santos
Luan Vinicius Miranda da Silva
Matheus Kaick Rocha da Fonseca
Rafael Pinto Germano Pereira

Agenda

Como os dados de manutenção da MecaniQA foram organizados para gerar as primeiras previsões de demanda.

1. Item:

Contexto do Negócio e Problema

2. Item:

Identificação e Correção do Outlier

3. Item:

Preparação e Limpeza dos Dados

4. Item:

Análise Exploratória de Dados

5. Item:

Cálculo das Previsões

6. Item:

Modelos Baseline e Resultados

7. Item:

Considerações Finais

Contexto do Negócio e Problema



- A **MecaniQA** é uma oficina que registra, todos os dias, quantas trocas de óleo e manutenções de motor realiza.
- Organizamos esse histórico e estudamos como a demanda por trocas de óleo se comportou ao longo do tempo
- A análise cobriu o período entre **janeiro de 2024 e dezembro de 2025, dia a dia.**
- Com os dados organizados, foi possível identificar os padrões de crescimento e repetição na demanda da oficina.



Identificação e Correção do Outlier

Como identificamos e corrigimos o outlier:

- O limite de valores aceitáveis foi calculado a partir da média e do desvio padrão da série
- Valores acima desse limite (como o erro de 150 trocas em um dia) foram ajustados automaticamente


```
# 1. Recarregar os dados originais do zero (sem tratamento prévio)
dados = pd.read_csv('mecânica_dataset - mecânica_dataset.csv.csv', parse_dates=['Data'])
dados = dados.set_index('Data').sort_index()

# 2. Cálculo do limite e tratamento
limite_superior = dados['Trocas_Oleo'].mean() + 3 * dados['Trocas_Oleo'].std()
dados['Trocas_Oleo_Original'] = dados['Trocas_Oleo'].copy()
dados['Trocas_Oleo'] = dados['Trocas_Oleo'].clip(upper=limite_superior)
```

Preparação e Limpeza dos Dados

Como cuidamos da base antes de qualquer análise:

- Dias sem registro no sistema foram preenchidos com base nos valores dos dias mais próximos
- Um erro de digitação registrou 150 trocas de óleo em um único dia; o valor foi corrigido para não distorcer a análise
- Ao final, os 731 dias da base (2024-2025) ficaram completos e prontos para análise




Análise Exploratória de Dados



Separando a série em três partes:

- Tendência: o crescimento da oficina ao longo dos dois anos, com uma queda em meados de 2024 seguida de recuperação
- Sazonalidade: um padrão que se repete toda semana, com dias de mais e de menos movimento
- Ruído: pequenas variações do dia a dia que não seguem nenhum padrão fixo



Cálculo das Previsões

Como calculamos as previsões:

- Os dias sem registro foram preenchidos antes de qualquer cálculo, garantindo uma série contínua
- O modelo Naive repete o valor do dia anterior como previsão para o próximo dia
- A Média Móvel de 7 dias suaviza as variações da semana, calculando a média dos últimos 7 registros
- A Média Móvel de 30 dias captura a tendência mais estável do mês, com uma janela maior de cálculo

```
# Garantindo preenchimento de dados ausentes antes dos modelos
serie_limpa = dados['Trocas_Oleo'].ffill().interpolate(method='time')

previsoes = pd.DataFrame(index=serie_limpa.index)
previsoes['Real'] = serie_limpa

# Modelos Baseline
previsoes['Naive'] = serie_limpa.shift(1)
previsoes['MM7'] = serie_limpa.rolling(window=7).mean()
previsoes['MM30'] = serie_limpa.rolling(window=30).mean()


display(previsoes.tail())
```

Modelos Baseline e Resultados



Três formas simples de prever a demanda:

- Naive: supõe que amanhã será igual a hoje
- Média Móvel de 7 dias: acompanha de perto as variações da semana
- Média Móvel de 30 dias: mostra a tendência mais suave do mês, ignorando picos e quedas do dia a dia



Considerações finais



- A base de dados ficou completa e sem falhas na linha do tempo, pronta para ser usada em análises futuras.
- Confirmamos que a demanda por trocas de óleo segue um padrão semanal bem definido, além de uma tendência de crescimento ao longo dos dois anos.
- Os modelos básicos já acompanham bem o comportamento real da demanda e servem como piso de comparação.

Referências

- FILHO, Mario. ***Como prever séries temporais univariadas usando Python***. Disponível em: <https://mariofilho.com/como-prever-series-temporais-univariadas-usando-python/>.
- DATACAMP. ***Análise e decomposição de séries temporais em Python***. Disponível em: <https://www.datacamp.com/pt/tutorial/time-series-decomposition>.
- NERD DOS DADOS. ***Como fazer SÉRIES TEMPORAIS com Python***. YouTube. Disponível em: <https://www.youtube.com/watch?v=yfVEymFbJSo>